Analyse de données et statistiques

Projet expension internaltion pour academy

Les différentes étapes pour la sélection des pays

Étape 1	Analyser et nettoyage les données
Étape 2	Réduire le périmètre de recherche
Etape 3	Choix des pays

01

Étape 1

Analyser et nettoyage les données

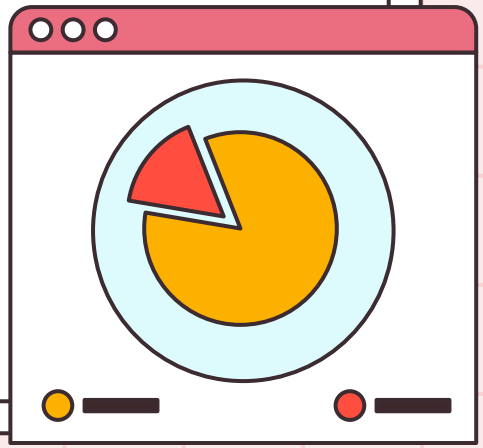

Les jeux de données à ma disposition

Fichier	Une ligne représente
EdStatsCountry-Series	un **indicateur** spécifique par **pays**
EdStatsCountry	un **pays** (+ **info** géographiques, économiques etc…)
EdStatsData	un **pays**, avec ses **valeurs** observées sur **plusieurs années**.
EdStatsFootNote	une note **explicative** associée à un **indicateur**, un **pays** et une **année** donnée
EdStatsSeries	**indicateur**, avec sa **définition**, son unité et ses métadonnées

Charge les jeux de donnés

```python
import pandas as pd
```

```python
country_series = pd.read_csv('EdStatsCountry-Series.csv')
country = pd.read_csv('EdStatsCountry.csv')
data = pd.read_csv('EdStatsData.csv')
footnote = pd.read_csv('EdStatsFootNote.csv')
series = pd.read_csv('EdStatsSeries.csv')
country_series.head(10)
```

	CountryCode	SeriesCode	DESCRIPTION	Unnamed: 3
0	ABW	SP.POP.TOTL	Data sources : United Nations World Population...	NaN
1	ABW	SP.POP.GROW	Data sources: United Nations World Population ...	NaN

Charge les jeux de donnés

```
country.tail()
```

	Country Code	Short Name	Table Name	Long Name	2-alpha code	Currency Unit	Special Notes	Region	Income Group	WB-2 code	...	IMF data dissemination standard	Latest population census	Latest household survey	Source of most recent Income and expenditure data	regi c
236	XKX	Kosovo	Kosovo	Republic of Kosovo	NaN	Euro	Kosovo became a World Bank member on June 29, ...	Europe & Central Asia	Lower middle income	KV	...	General Data Dissemination System (GDDS)	2011	NaN	Integrated household survey (IHS), 2011	

```
data.head()
```

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060	2065	2070	2075	2080	2085	2090	209
0	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na

Nettoyages réalisé :

Suppression des doublons

Suppression des données manquantes

Suppression des faux pays

Nettoyage des données

Nombre de lignes et de colonnes pour chaque jeux de données

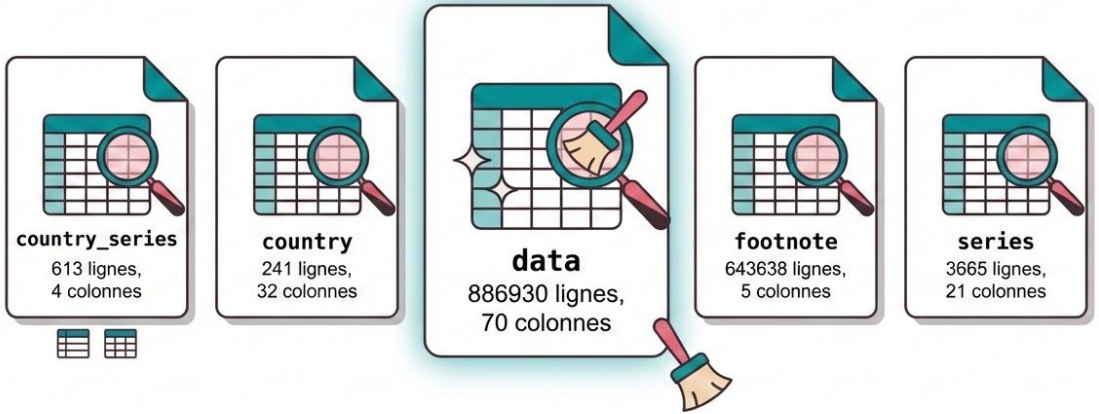

Il faut absolument automatiser car beaucoup de ligne

Nettoyage des données

Vérification des doublon :

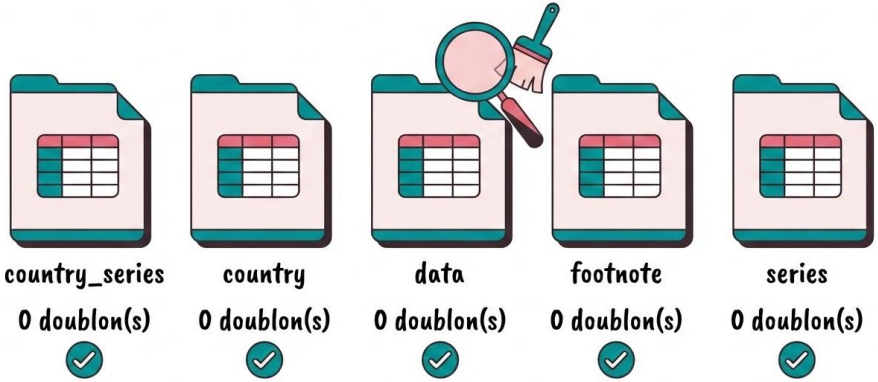

Nettoyage des données

Suppression des données trop manquantes

Calculez la proportion de valeurs manquantes par colonne.
- Supprimez les colonnes inutilisables (assez vague)

- **Calculez la proportion de valeurs manquantes par colonne.**

Suppression des colonnes contenant plus de 90 % de données manquantes

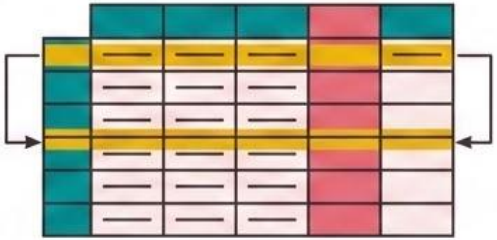

Exemple de résultat :

```
*** Nettoyage du DataFrame data **
45 colonnes supprimées (>=90% de valeurs manquantes
Colonnes supprimées : 1970, 1971, 1972, 1973, 1974, 1975, 1976, 1977, 1978, 1979, 1981, 198
1983, 1984, 1986, 1987, 1988, 1989, 1991, 1992, 1993, 1994, 1996, 1997, 1998, 2016, 201
2020, 2025, 2030, 2035, 2040, 2045, 2050, 2055, 2060, 2065, 2070, 2075, 2080, 2085, 209
2095, 2100, Unnamed: 6
```

Nettoyage des données

series.describe() ***-calculez statistiques descriptives pour colonnes numériques***

*** Statistiques descriptives pour series ***

	Series Code	Topic	Indicator Name	Short definition	Long definition	Other notes	Source
count	3665	3665	3665	2156	3665	552	3665
unique	3665	37	3665	1169	2060	14	31
top	XGDP.56.FSGOV.FDINSTADM.FFD	Learning Outcomes	Government expenditure in tertiary institution...	Data Interpretation: 1=Latent; 2=Emerging; 3=E...	Data Interpretation: 1=Latent; 2=Emerging; 3=E...	EGRA	UNESCO Institute for Statistics
freq	1	1046	1	215	215	403	1269

📊 Analyse descriptive – Dataframe *series*

Structure du dataset	Répartition thématique	Qualité de la documentation	Sources
- 3 665 indicateurs uniques (`Series Code`) - Aucun doublon → table de référence fiable - 37 thématiques identifiées	- Forte concentration sur *Learning Outcomes* (~28%) - Focus dominant sur les indicateurs liés à l'éducation	- 59% disposent d'une *short definition* - 100% disposent d'une *long definition* - Certaines définitions longues sont génériques	- 31 organismes différents - L'UNESCO représente ~35% des indicateurs

Nettoyage des données

- calculez le nombre d'occurrences colonnes catégorielles

```
data["Indicator Code"].value_counts(dropna=False)
```

```
Indicator Code
SE.ADT.1524.LT.MA.ZS    242
PRJ.POP.ALL.4.FE        242
PRJ.POP.ALL.NED.MF      242
PRJ.POP.ALL.NED.MA      242
PRJ.POP.ALL.NED.FE      242
                       ...
SE.PRM.TENR.FE          242
SE.PRM.TENR             242
UIS.NERA.2.M            242
UIS.NERA.2.GPI          242
UIS.NERA.2.F            242
Name: count, Length: 3665, dtype: int64
```

- 3 665 indicateurs distincts

- Chaque indicateur apparaît 242 fois

- Correspond probablement à 242 pays / entités

- Structure homogène et complète

Nettoyage des données

- ***Suppression des faux pays (assez vague)***

✔ *Reconnue par l'ONU*

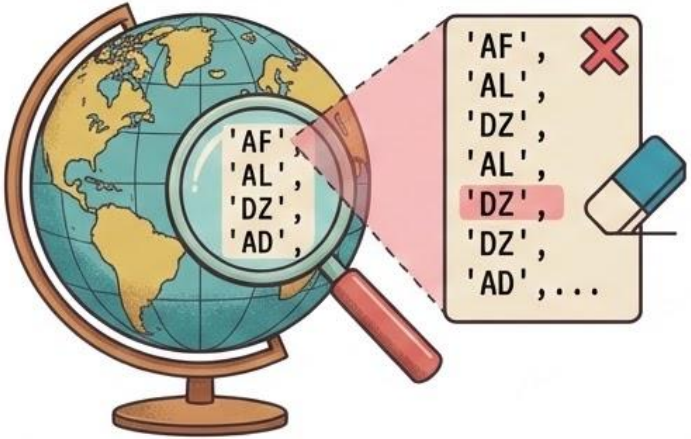


```
Alpha_code = ['AF', 'AL', 'DZ', 'AD',...]
```

Taille avant :

241 → 192

Taille après filtrage alpha : 192

	Country Code	Short Name	Table Name	Long Name	2-alpha code	Currency Unit
236	XXX	Kosovo	Kosovo	Republic of Kosovo	NaN	Euro
237	YEM	Yemen	Yemen, Rep.	Republic of Yemen	YE	Yemeni rial
238	ZAF	South Africa	South Africa	Republic of South Africa	ZA	South African rand

Nettoyage des données

Fusionner les données

Étape 1: Fusionner 'country' avec 'country series' en utilisant utilsant comme clé “Country Code”

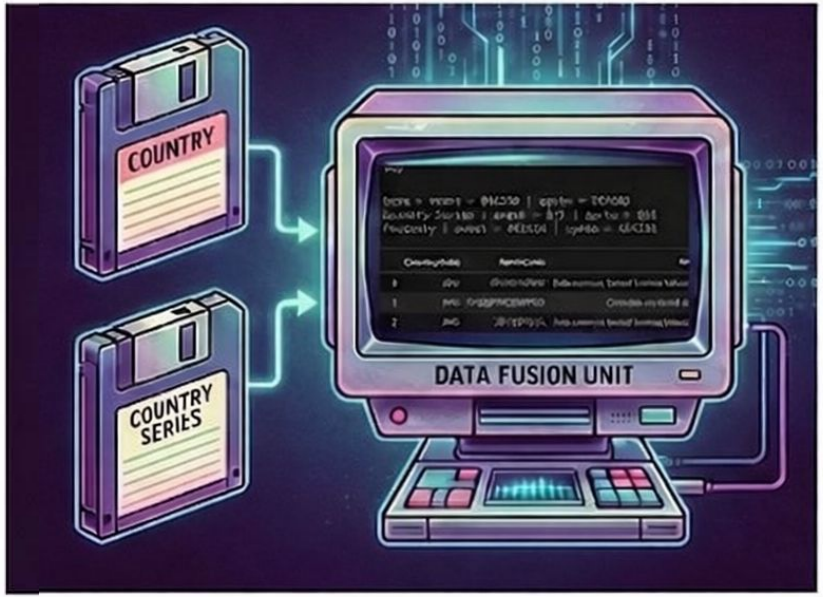

Étape 2 : Fusionner country avec les autres data frame en utilisant comme clé “Country Code”

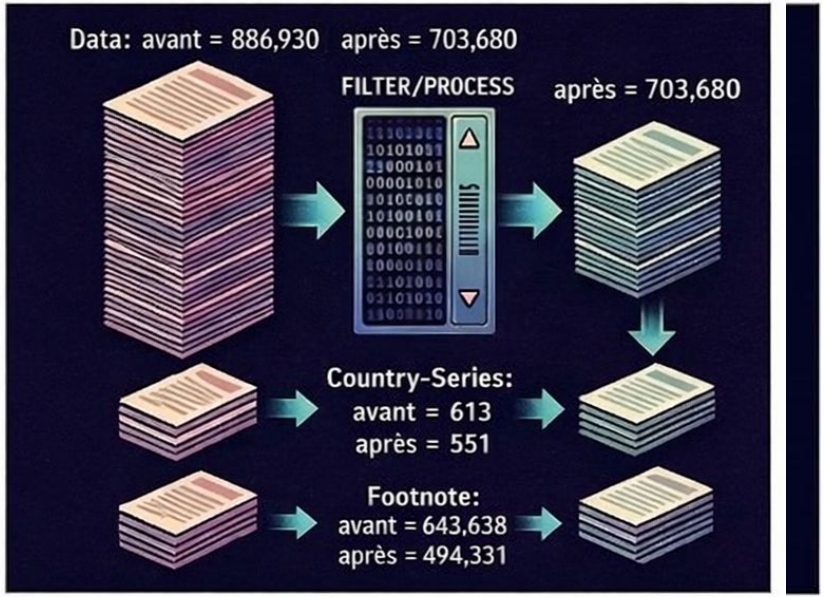

02

Étape 2

Réduire le périmètre de recherche

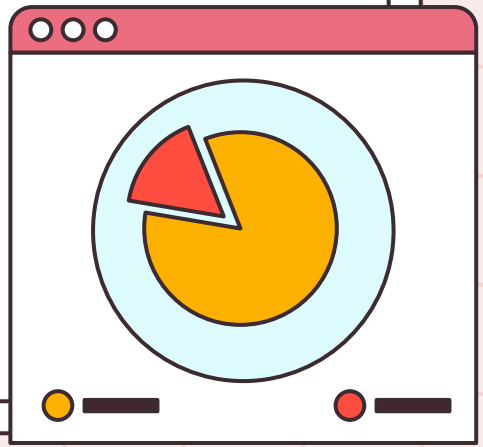

Réduction du périmètre de recherche

Sélection des années qui nous intéresse

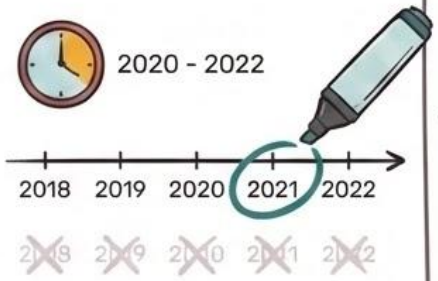

sélection des topics et indicateurs à garder

suppression des indicateurs redondants

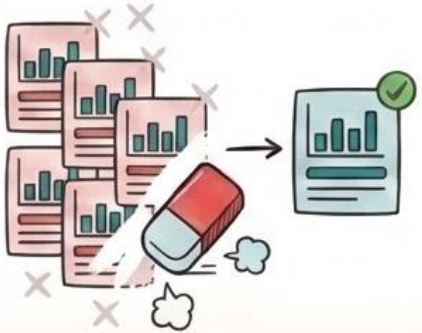

Réduction du périmètre de recherche

Sur 37 catégorie a la base 25 on été retenue qui sont en rapport avec notre projet d'expansion à l'international

Exemple topics retenue :	Exemple topics non retenue:
Education Equality Utile : Pour cibler des populations spécifiques (ex: bourses, accès femmes). **Secondary Cœur de cible** : Votre marché principal n°1. **Population** Indispensable : La taille du marché global. **Tertiary** Cœur de cible : Votre marché principal n°2.	**Early Childhood Education** (Éducation de la petite enfance) **Pre-Primary** école primaire **Early Child Development** Développement de la petite enfance

J'ai filtré le DataFrame 'series' pour garder les topics pertinents, puis j'ai utilisé ce filtrage pour appliquer le même critère sur les autres DataFrames

```
Series : 3665  → 3309
Data : 703680 → 628224
Country-Series : 551 → 546
Footnote : 494331 → 289558
```

Réduction du périmètre de recherche

Sélection années	Sélection des indicateur à garder	Suppression indicateur redondant
- Sélection des 15 années avec le moins de données manquantes	- Sélection des 15 indicateurs les plus fréquents + indicateur effectifs étudiants sup	-si corrélation (0.9 entre indicateur = suppression (5 indicateurs supprimés)
2010 31.250796 2005 22.764492 2015 18.243811 2012 16.560176 2011 16.423919 2006 16.043640 2009 15.926007 2007 15.301071 2013 15.127407 etc…	- Suppression des pays où 1 seul de ces indicateurs est manquant (192–>104 pays)	*Indicateurs homme/femme ont été suprimés car très forte corrélation avec les indicateurs globaux*

Réduction du périmètre de recherche

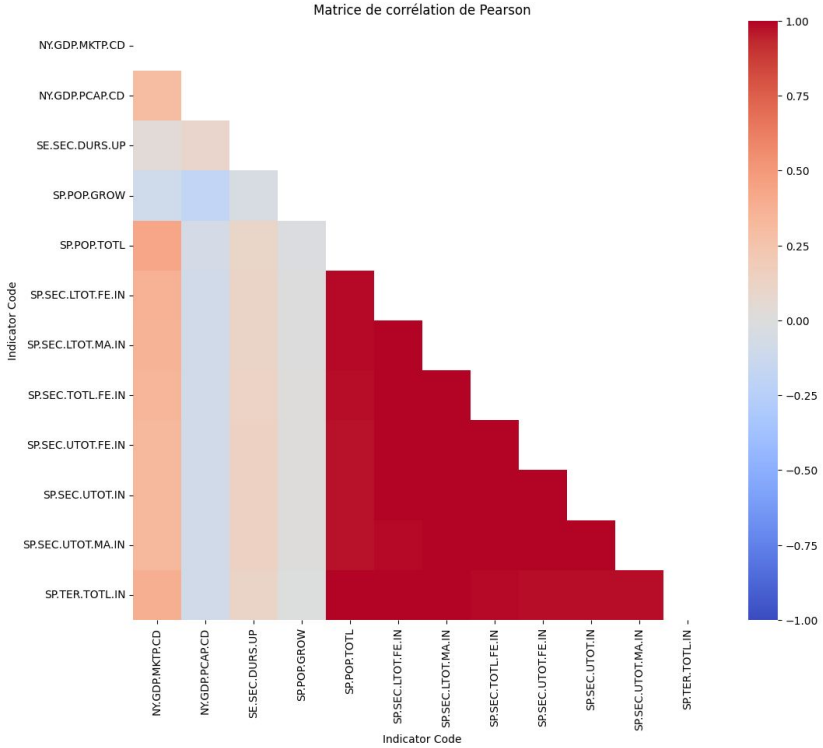

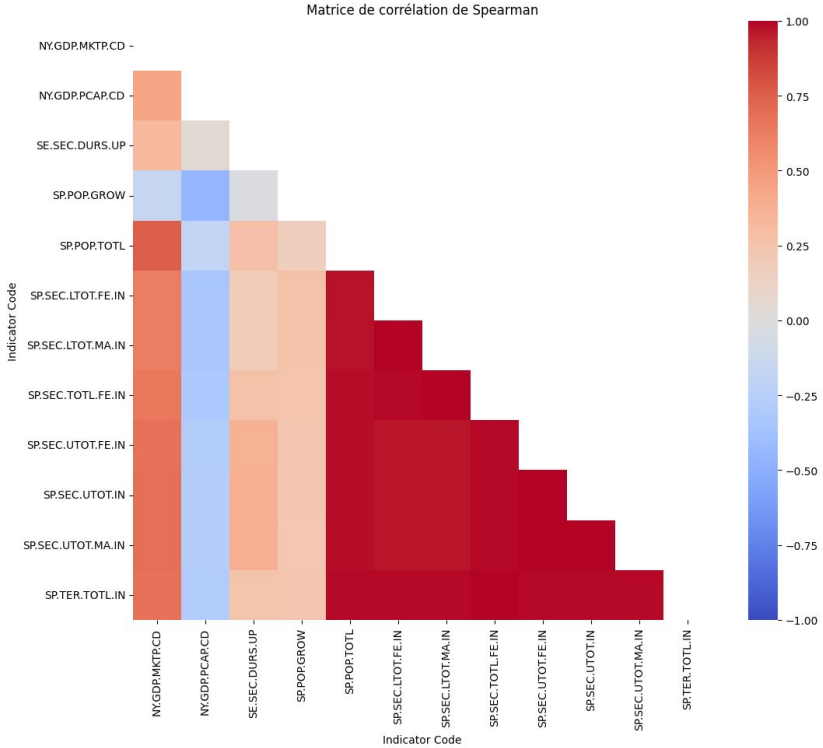

Réduction du périmètre de recherche

Indicateur qui on été supprimer

Indicateur supprimer	Corrélé avec
SP.SEC.TOTL.FE.IN : Population filles secondaire (cycle 1 et 2)	**SP.SEC.UTOT.IN** Population total cycle 2 (0.989000)
SP.SEC.LTOT.FE.IN : Population filles secondaire (1er cycle)	**SP.SEC.LTOT.IN** Population total cycle 1 (0.999659)
SP.SEC.LTOT.MA.IN : Population garçons secondaire (1er cycle)	**SP.SEC.UTOT.IN** Population total cycle 1 (0.967108)
SP.SEC.UTOT.FE.IN : Population filles secondaire (2nd cycle)	**SP.SEC.UTOT.IN** Population Totale cycle 2 (0.999915)
SP.SEC.UTOT.MA.IN : Population garçons secondaire (2nd cycle)	**SP.SEC.UTOT.IN** Population Totale cycle 2(0.999883)

03

Étape 3

Choix des pays

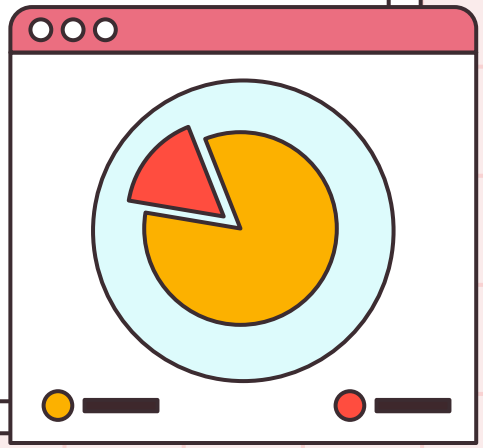

Analyse indicateur

- analyse chaque indicateur avec la fonction describ et je réalise un traçage des résultats avec une interprétation résultat

Sélection des pays avec coefficient

-réalisation d’une méthode de scoring pondéré a été mise en place

Analyse indicateur exemple avec indicateur : *SP.TER.TOTL.IN*

SP.TER.TOTL.IN – Nombre total d'étudiants dans l'enseignement supérieur

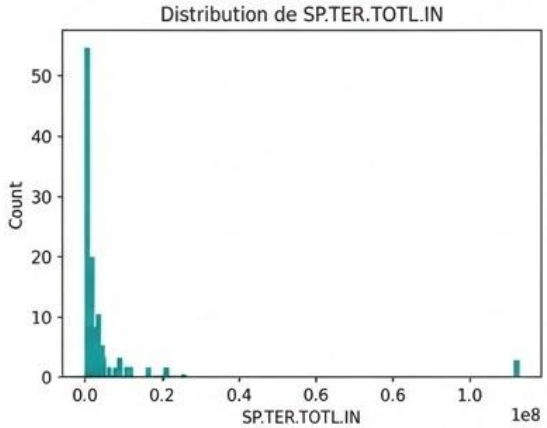


```
Analyse de l'indicateur : SP.TER.TOTL.IN
count    1.04000e+02
mean     4.10174e+02
std      1.56702e+07
min      4.56333e+03
25%      3.08466e+05
58%      7.09566e+06
75%      2.24571e+06
max      1.14322e+08
Name: SP.TER.TOTL.IN, dtype: float64
```

Interprétation des résultats :

- La distribution est fortement asymétrique à droite.
- La moyenne est largement supérieure à la médiane, indiquant la présence de quelques pays avec un nombre d'étudiants très élevé qui tirent la moyenne vers le haut.
- La majorité des pays présente un volume d'étudiants relativement limité, traduisant une forte hétérogénéité.
- Cet indicateur est directement lié à la taille de la population et constitue un élément clé pour évaluer le potentiel de marché, à condition d'être combiné à des indicateurs économiques.

méthode de scoring pondéré :

L'Algorithme : "Score Academy"

1. Coefficient 8 : PIB par Habitant (Richesse)

- **Pourquoi :** C’est la **SOLVABILITÉ**.
- *Justification :* Priorité absolue : on vise des clients capables de payer le service.

2. Coefficient 3 : Élèves & Étudiants (Éducation)

- **Pourquoi :** C’est la **DEMANDE**.
- *Justification :* On cible le volume de jeunes qui vont réellement à l'école.

3. Coefficient 3 : PIB National (Économie)

- **Pourquoi :** C’est la **STABILITÉ**.
- *Justification :* On privilégie les économies solides pour sécuriser l'investissement.

4. Coefficient 1 : Population Totale (Taille)

- C’est **BONUS**.
- *Justification :* La taille du pays compte, mais moins que la richesse de ses habitants.

méthode de scoring pondéré :

L'Algorithme : "Score Academy"

CLASSEMENT DES MEILLEURS PAYS SELON NOTRE PROJET

Pays	Drapeau	Code	Score Academy
United States		USA	8.734119
Norway		NOR	8.090973
Switzerland		CHE	7.037271
China		CHN	5.839712
Denmark		DNK	5.506517
India		IND	5.233879
Ireland		IRL	5.223628
Sweden		SWE	5.076600
Allemany		DEU	4.869964
Australia		AUS	4.839981

Analyse

✅ Points forts

- Données couvrant plusieurs dimensions clés : éducation, économie, démographie
- Indicateurs adaptés à l’objectif d’expansion d’une academy
- Données nettoyées et non redondantes, permettant des comparaisons fiables
- Construction d’un score global pour classer les pays de manière objective

⚠️ Limites

- Données agrégées au niveau national (pas de vision locale)
- Absence de facteurs qualitatifs (réglementation, concurrence, culture)
- Données statiques ne reflétant pas forcément les évolutions récentes

Conclusion

🎯 Conclusion

- Jeu de données pertinent pour une **première analyse stratégique**
- Bon point de départ pour identifier des pays à fort potentiel
- Analyse à compléter avant une décision finale d’implantation